

第五章 不确定推理

- 基本概念
- 概率方法
- 主观Bayes方法
- 可信度方法
- 模糊理论
- 简单模糊推理

5.1 基本概念

5.1.1 什么是不确定性推理

- 不确定性推理是建立在非经典逻辑基础上的一种推理，它是对不确定性知识的运用与处理。
- 具体地说，不确定性推理就是从不确定性的初始证据（即事实）出发，通过运用不确定性的知识，最终推出具有一定程度不确定性的结论。

5.1.2 不确定性推理中的基本问题

- 不确定性的表示
- 不确定性的匹配
- 组合证据的不确定性的计算
- 不确定性的更新
- 不确定性结论的合成

5.1.2 不确定性推理中的基本问题

1. 不确定性的表示与度量

- 不确定性推理中的“不确定性”一般分为两类：一是知识的不确定性，一是证据的不确定性。
- 知识不确定性的表示：目前在专家系统中知识的不确定性一般是由领域专家给出的，通常用一个数值表示，它表示相应知识的不确定性程度，称为知识的静态强度。
- 证据不确定性的表示：证据不确定性的表示方法与知识不确定性的表示方法一致，通常也用一个数值表示，代表相应证据的不确定性程度，称之为动态强度。



2. 不确定性匹配算法及阈值的选择

- 设计一个不确定性匹配算法;
- 指定一个匹配阈值。

3. 组合证据不确定性的计算方法

当知识的前提条件是多个证据的组合时，需要进行合成。

□ 最大最小法：

$$T(E_1 \text{ AND } E_2) = \min\{T(E_1), T(E_2)\}$$

$$T(E_1 \text{ OR } E_2) = \max\{T(E_1), T(E_2)\}$$

□ 概率法：

$$T(E_1 \text{ AND } E_2) = T(E_1) \times T(E_2)$$

$$T(E_1 \text{ OR } E_2) = T(E_1) + T(E_2) - T(E_1) \times T(E_2)$$

□ 有界法：

$$T(E_1 \text{ AND } E_2) = \max\{0, T(E_1) + T(E_2) - 1\}$$

$$T(E_1 \text{ OR } E_2) = \min\{1, T(E_1) + T(E_2)\}$$

其中， $T(E)$ 表示证据 E 为真的程度（动态强度），如可信度、概率等。

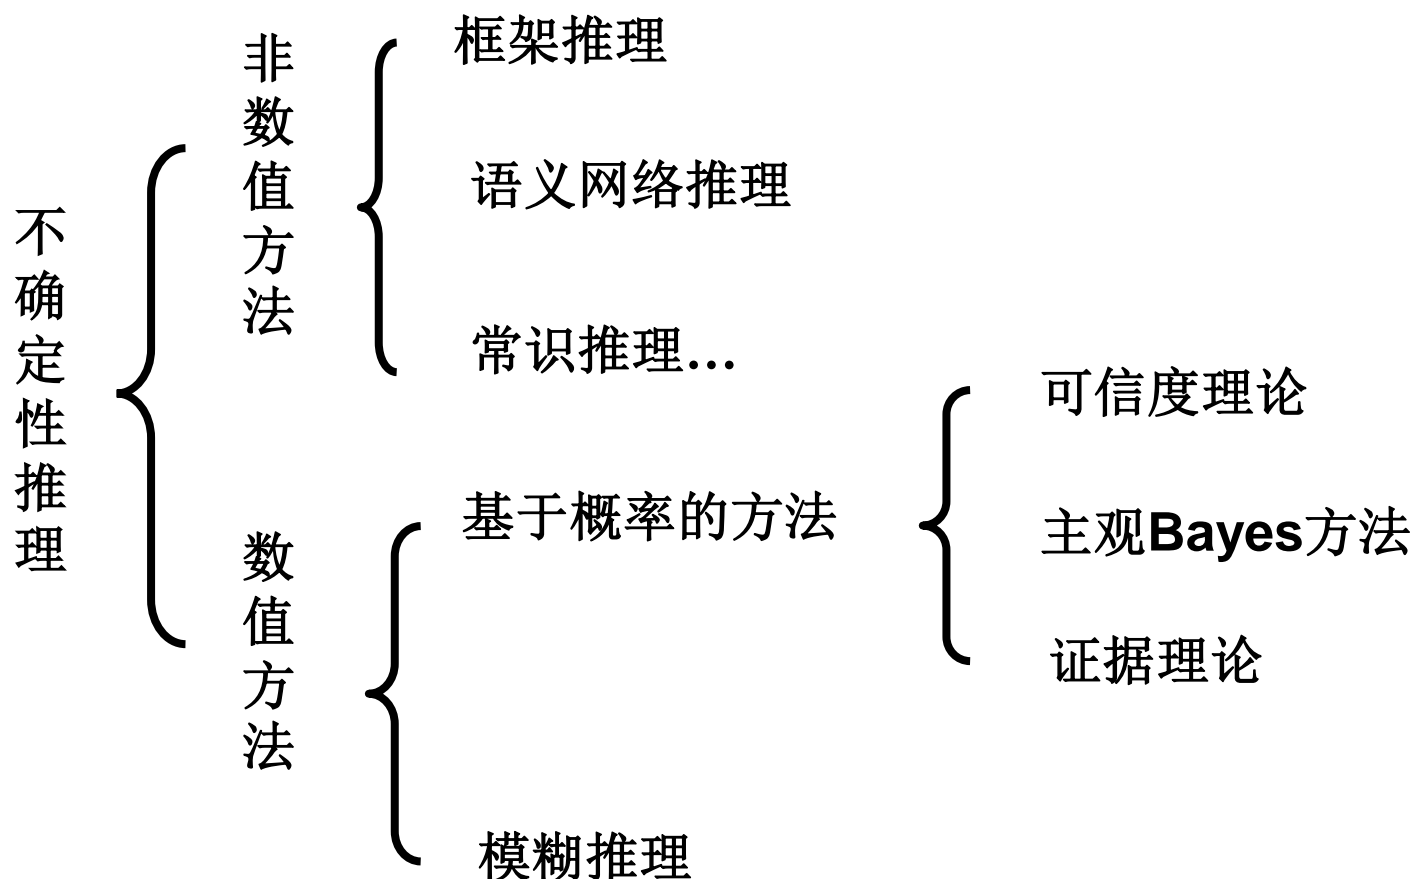
4. 不确定性的传递算法

在每一步推理中，如何把知识的不确定性传递给结论，即如何计算结论的不确定性。

5. 结论不确定性的合成

用不同知识进行推理得到了相同结论，但所得结论的不确定性却不同。此时，需要用合适的算法对结论的不确定性进行合成。

5.1.3 不确定性推理方法的分类



5.2 概率方法

5.2.1 经典概率方法

(1) 设有如下产生式规则：

IF E THEN H

其中，**E**为前提条件，**H**为结论。条件概率 $P(H|E)$ 可以作为在证据**E**出现时结论**H**的确定性程度，即规则的静态强度。

(2) 对于复合条件

$E=E_1 \text{ AND } E_2 \text{ AND } \dots \text{ AND } E_n$

当已知条件概率 $P(H|E_1, E_2, \dots, E_n)$ 时，就可把它作为在证据 **E_1, E_2, \dots, E_n** 出现时结论**H**的确定性程度。

(3) 先验概率： $P(H)$ 后验概率： $P(H|E)$

- 把贝叶斯公式用于不确定推理的思想
 - 已知前提**E**的概率**P(E)**和结论**H**的先验概率**P(H)**
 - 已知**H**成立时**E**出现的条件概率**P(E|H)**
 - 利用规则推出**H**在**E**出现的条件下的后验概率:

$$P(H | E) = \frac{P(E | H)P(H)}{P(E)}$$

- 若 A_1, A_2, \dots, A_n 是彼此独立的事件，对于事件 B ，则有

$$P(A_i | B) = \frac{P(A_i) \times P(B | A_i)}{\sum_{j=1}^n P(A_j) \times P(B | A_j)}, i = 1, 2, \dots, n$$

其中， $P(A_i)$ 是事件 A_i 的先验概率； $P(B|A_i)$ 是在事件 A_i 发生条件下事件 B 的条件概率。

- 对于一组产生式规则

IF E THEN H_i

同样有后验概率如下（ H_i 确定性的程度，或规则的静态强度）：

$$P(H_i | E) = \frac{P(H_i) \times P(E | H_i)}{\sum_{j=1}^n P(H_j) \times P(E | H_j)}, i = 1, 2, \dots, n$$

对于多个证据

◆ 对于有多个证据**E1, E2, ..., Em**和多个结论**H1, H2, ... Hn**, 并且每个证据都以一定程度支持结论的情况, 上面的式子可进一步扩展为

$$P(H_i | E_1 E_2 \cdots E_m)$$
$$= \frac{P(H_i) \times P(E_1 | H_i) \times P(E_2 | H_i) \times \cdots \times P(E_m | H_i)}{\sum_{j=1}^n P(H_j) \times P(E_1 | H_j) \times P(E_2 | H_j) \times \cdots \times P(E_m | H_j)}$$

, $i = 1, 2, \dots, n$

概率方法举例

例1 .设 H_1, H_2, H_3 分别是三个结论， E 是支持这些结论的证据。
已知：

$$P(H_1)=0.3, \quad P(H_2)=0.4, \quad P(H_3)=0.5$$

$$P(E|H_1)=0.5, \quad P(E|H_2)=0.3, \quad P(E|H_3)=0.4$$

求 $P(H_1|E), P(H_2|E)$ 及 $P(H_3|E)$ 的值各是多少？

解：

$$\begin{aligned} P(H_1|E) &= \frac{P(H_1) \times P(E|H_1)}{P(H_1) \times P(E|H_1) + P(H_2) \times P(E|H_2) + P(H_3) \times P(E|H_3)} \\ &= \frac{0.15}{0.15 + 0.12 + 0.2} \\ &= 0.32 \end{aligned}$$

同理可得： $P(H_2|E)=0.26, P(H_3|E)=0.43$

对应的产生式规则：

IF E THEN H_1

IF E THEN H_2

IF E THEN H_3

规则的静态强度(H_i 为真的程度、或不确定性程度)

$P(H_1|E)=0.32$, $P(H_1)=0.3$,

$P(H_2|E)=0.26$, $P(H_2)=0.4$,

$P(H_3|E)=0.43$, $P(H_3)=0.5$,

由于**E**的出现, H_1 成立的可能性增加, H_2 和 H_3 成立的可能性不同程度的下降。

例2 .设 H_1, H_2, H_3 分别是三个结论, E_1, E_2 是支持这些结论的证据。已知:

$$P(H_1)=0.4; \quad P(H_2)=0.3; \quad P(H_3)=0.3$$

$$P(E_1|H_1)=0.5; \quad P(E_1|H_2)=0.6; \quad P(E_1|H_3)=0.3.$$

$$P(E_2|H_1)=0.7; \quad P(E_2|H_2)=0.9; \quad P(E_2|H_3)=0.1$$

求 $P(H_1|E_1E_2), P(H_2|E_1E_2)$ 及 $P(H_3|E_1E_2)$ 的值各是多少?

解:

$$\begin{aligned} & P(H_1|E_1E_2) \\ &= \frac{P(H_1)P(E_1|H_1)P(E_2|H_1)}{P(H_1)P(E_1|H_1)P(E_2|H_1) + P(H_2)P(E_1|H_2)P(E_2|H_2) + P(H_3)P(E_1|H_3)P(E_2|H_3)} \\ &= 0.45 \end{aligned}$$

同理可得：

$$P(H_2|E_1E_2)=0.52$$

$$P(H_3|E_1E_2)=0.03$$

可见，由于 E_1 和 E_2 的出现， H_1 和 H_2 成立的可能性不同程度的增加， H_3 成立的可能性下降。

概率法的特点

优点：

- 概率法有较强的理论背景和良好的数学特性，当证据彼此独立时计算的复杂度比较低。

缺点：

- 概率法要求给出结论 H_i 的先验概率 $P(H_i)$ 及条件概率 $P(E_j|H_i)$ 。

5.3 主观Bayes方法

- 使用概率推理方法求结论 H_i 在存在证据 E 时的条件概率 $P(H_i|E)$ ，需要给出结论 H_i 的先验概率 $P(H_i)$ 及证据 E 的条件概率 $P(E|H_i)$ 。这对于实际应用是不容易做到的。
- **Duda 和 Hart** 等人在贝叶斯公式的基础上，于**1976**年提出主观贝叶斯方法，建立了不精确推理的模型，并把它成功地应用于**PROSPECTOR**专家系统（**PROSPECTOR**是国际上著名的一个用于勘察固体矿的专家系统）。

- 在主观Bayes方法中，知识是用产生式表示的，其形式为：

IF E THEN (LS, LN) H


- **E**表示规则前提条件，它既可以是一个简单条件，也可以是用**AND**或**OR**把多个简单条件连接起来的复合条件。
- **H**是结论，用**P(H)**表示**H**的先验概率，它指出没有任何专门证据的情况下结论**H**为真的概率，其值由领域专家根据以往的实践经验给出。

- **LS**是规则的充分性度量。用于指出**E**对**H**的支持程度，取值范围为 $[0, +\infty)$ ，其定义为：

$$LS = \frac{P(E | H)}{P(E | \neg H)}$$

- **LN**是规则的必要性度量。用于指出**E**对**H**为真的必要程度，即**¬E**对**H**的支持程度。取值范围为 $[0, +\infty)$ ，其定义为：

$$LN = \frac{P(\neg E | H)}{P(\neg E | \neg H)} = \frac{1 - P(E | H)}{1 - P(E | \neg H)}$$



PROSPECTOR的不确定性推理过程，就是根据证据的概率 $P(E)$ 或 $P(E|S)$ ，利用LS或LN，把结论 H 的先验概率 $P(H)$ 更新为后验概率 $P(H|E)$ 的过程。



主观贝叶斯方法

- **1. 知识不确定性的表示**
- **2. 证据不确定性的表示**
- **3. 组合证据不确定性的计算**
- **4. 不确定性的传递算法**
- **5. 不确定性结论的合成**

5.3.1 知识不确定性的表示

在主观**Bayes**方法中，知识是用产生式规则表示的，具体形式为：

IF E THEN (LS, LN) H (P(H))

其中，

- **P(H)**是结论**H**的先验概率，由专家根据经验给出。
- **LS**称为充分性度量，用于指出**E**对**H**的支持程度。
- **LN**称为必要性度量，用于指出 \neg **E**对**H**的支持程度。
- **LS**和**LN**的值由领域专家给出，相当于知识的静态强度。

■ 讨论LS和LN的含义

- 由Bayes公式可知:

$$P(H | E) = \frac{P(E | H) \times P(H)}{P(E)}$$

$$P(\neg H | E) = \frac{P(E | \neg H) \times P(\neg H)}{P(E)}$$

- 两式相除得:

$$\frac{P(H | E)}{P(\neg H | E)} = \frac{P(E | H)}{P(E | \neg H)} \times \frac{P(H)}{P(\neg H)}$$

$$LS = \frac{P(E | H)}{P(E | \neg H)}$$

- 引入几率函数 $\Theta(x)$,它与概率的关系为:

$$\Theta(x)=P(x)/(1-P(x)),$$

$$P(x)=\Theta(x)/(1+\Theta(x))$$

它表示 x 的出现概率与不出现概率之比,显然随 $P(x)$ 的加大 $\Theta(x)$ 也加大, 且

$$\text{当 } P(x)=0 \text{ 时, 有 } \Theta(x)=0$$

$$\text{当 } P(x)=1 \text{ 时, 有 } \Theta(x)=\infty$$

于是, 取值于 $[0,1]$ 的 $P(x)$ 被放大为取值于 $[0, \infty]$ 的 $\Theta(x)$ 。

■ 讨论LS和LN的含义

- 因此得到关于LS的公式： E对H的支持程度

$$\Theta(H | E) = \frac{P(H | E)}{P(\neg H | E)} = \frac{P(E | H)}{P(E | \neg H)} \times \frac{P(H)}{P(\neg H)} = LS \times \Theta(H)$$

- 同理得到关于LN的公式： \neg E对H的支持程度


$$\Theta(H | \neg E) = \frac{P(H | \neg E)}{P(\neg H | \neg E)} = \frac{P(\neg E | H)}{P(\neg E | \neg H)} \times \frac{P(H)}{P(\neg H)} = LN \times \Theta(H)$$

5.3.2 证据不确定性的表示

- 在主观**Bayes**方法中，证据的不确定性也用概率表示。对于证据**E**，由用户根据观察**S**给出 **$P(E|S)$** ，即动态强度。用 **$P(E|S)$** 描述证据的不确定性（证据**E**不是可以直接观测的）。
- 由于主观给定 **$P(E|S)$** 有所困难，所以实际中可以用可信度 **$C(E|S)$** 代替 **$P(E|S)$** 。

- 给定 $C(E|S)$ 后, $P(E|S)$ 可近似计算如下:

$$P(E|S)=\begin{cases} \frac{C(E|S)+P(E)\times(5-C(E|S))}{5} & ,0\leq C(E|S)\leq 5 \\ \frac{P(E)\times(5+C(E|S))}{5} & , -5\leq C(E|S)<0 \end{cases}$$



例如, 在PROSPECTOR中 $C(E|S)$ 取整数:
 $\{-5, \dots, 5\}$

- $C(E|S)=-5$ 表示在观测 S 下证据 E 肯定不存在, $P(E|S)=0$
- $C(E|S)=5$ 表示在观测 S 下证据 E 肯定存在, $P(E|S)=1$
- $C(E|S)=0$ 表示 S 与 E 无关, 即 $P(E|S)=P(E)$

5.3.3 组合证据不确定性的算法

(1) 最大最小法

当组合证据是多个单一证据的合取时，即

$$E = E_1 \text{ AND } E_2 \text{ AND } \dots \text{ AND } E_n$$

则： $P(E|S) = \min\{P(E_1|S), P(E_2|S), \dots, P(E_n|S)\}$

当组合证据是多个单一证据的析取时，即

$$E = E_1 \text{ OR } E_2 \text{ OR } \dots \text{ OR } E_n$$

则： $P(E|S) = \max\{P(E_1|S), P(E_2|S), \dots, P(E_n|S)\}$

(2) 对于 “ \neg ”运算则： $P(\neg E|S) = 1 - P(E|S)$

5.3.4 不确定性的传递算法

- 根据证据**E**的条件概率 **$P(E|S)$** 及**LS**、**LN**的值，把**H**的先验概率 **$P(H)$** 更新为后验概率 **$P(H|S)$** 。
- 分以下**3**种情况讨论：
 - 证据肯定存在： $P(E|S)=1$ ， 即 **$P(E)=1$**
 - 证据肯定不存在： $P(E|S)=0$ ， 即 **$P(E)=0$**
 - 证据不确定： $0 < P(E|S) < 1$

证据肯定存在时

- 当证据**E**肯定存在时， $P(H|S) = P(H|E)$ 。于是
 $\Theta(H|S) = \Theta(H|E)$ 。将**H**的先验几率 $\Theta(H)$ 更新为后验几率 $\Theta(H|S)$ 的公式为：

$$\Theta(H|S) = \Theta(H|E) = LS \times \Theta(H)$$

- 把**H**的先验概率**P(H)**更新为后验概率**P(H|S)**的公式为：

$$P(H | S) = P(H | E) = \frac{LS \times P(H)}{(LS - 1) \times P(H) + 1}$$

$$\begin{aligned}\Theta(x) &= P(x)/(1-P(x)), \\ P(x) &= \Theta(x)/(1+\Theta(x))\end{aligned}$$

充分性度量LS的意义

- 对于知识：

IF E THEN (LS, LN) H (P(H))

在证据E肯定存在时，可以根据LS给出结论H的可信度P(H|E)。

- 当 $LS > 1$ 时， $\Theta(H|E) = LS \times \Theta(H) > \Theta(H)$ ，相应地有 $P(H|E) > P(H)$ ，表明由于证据E的存在，可增强H为真的程度（有利证据）。一般情况下 $LS > 1$ 。
- 当 $LS = 1$ 时， $\Theta(H|E) = LS \times \Theta(H) = \Theta(H)$ ，表明E与H无关（无关证据）。
- 当 $LS < 1$ 时， $\Theta(H|E) = LS \times \Theta(H) < \Theta(H)$ ，表明由于证据E的存在，减小了H为真的程度（不利证据）。
- 当 $LS = 0$ 时， $\Theta(H|E) = LS \times \Theta(H) = 0$ ，表明由于证据E的存在，导致H为假（否定性的证据）。

证据肯定不存在时

- 当证据**E**肯定不存在时, $P(H|S) = P(H|\neg E)$ 。于是
 $\Theta(H|S) = \Theta(H|\neg E)$ 。将**H**的先验几率 $\Theta(H)$ 更新为后验几率 $\Theta(H|S)$ 的公式为:

$$\Theta(H|S) = \Theta(H|\neg E) = LN \times \Theta(H)$$

- 把**H**的先验概率**P(H)**更新为后验概率**P(H|S)**的公式为:

$$P(H | S) = P(H | \neg E) = \frac{LN \times P(H)}{(LN - 1) \times P(H) + 1}$$

必要性度量LN的意义

- 对于知识：

IF E THEN (LS, LN) H (P(H))

在证据E肯定不存在时，可以根据LN给出结论H的可信度 $P(H|\neg E)$ 。

- 当 $LN < 1$ 时， $\Theta(H|\neg E) = LN \times \Theta(H) < \Theta(H)$ ，表明由于证据E不存在，减小了H为真的程度（ $\neg E$ 为不利证据）。

一般情况下 $LN < 1$ 。

当 $LN = 0$ 时， $\Theta(H|\neg E) = LN \times \Theta(H) = 0$ ，表明由于证据E不存在，导致H为假（表明了证据E的必要性）。

- 当 $LN = 1$ 时， $\Theta(H|\neg E) = LN \times \Theta(H) = \Theta(H)$ ，表明 $\neg E$ 与H无关。

- 当 $LN > 1$ 时， $\Theta(H|\neg E) = LN \times \Theta(H) > \Theta(H)$ ，相应 有 $P(H|\neg E) > P(H)$ ，表明由于证据E不存在，增强了H为真的程度（ $\neg E$ 为有利证据）。

$LS > 1$: 表明证据 E 是对 H 有利的证据。

$LN > 1$: 表明证据 $\neg E$ 是对 H 有利的证据。

所以: 不能出现 $LS > 1$ 且 $LN > 1$ 的取值。

$LS < 1$: 表明证据 E 是对 H 不利的证据。

$LN < 1$: 表明证据 $\neg E$ 是对 H 不利的证据。

所以: 不能出现 $LS < 1$ 且 $LN < 1$ 的取值。

一般情况下, 取 $LS > 1$, $LN < 1$ 。

证据不确定时

当 $0 < P(E|S) < 1$ 时，可以证明：

$$P(H|S) = P(H|E) \times P(E|S) + P(H|\neg E) \times P(\neg E|S)$$

- 当 $P(E|S)=1$ 时，证据肯定存在，此时 $P(H|S)=P(H|E)$ 。
- 当 $P(E|S)=0$ 时，证据肯定不存在，此时 $P(H|S)=P(H|\neg E)$ 。
- 当 $P(E|S)=P(E)$ 时，证据 E 与观察 S 无关。由全概率公式得：

$$P(H|S) = P(H|E) \times P(E) + P(H|\neg E) \times P(\neg E) = P(H)$$

- 当 $P(E|S)$ 为其它值时，通过分段线性插值计算 $P(H|S)$ ，即

$$P(H|S) = \begin{cases} P(H|\neg E) + \frac{P(H) - P(H|\neg E)}{P(E)} \times P(E|S) & , 0 \leq P(E|S) < P(E) \\ P(H) + \frac{P(H|E) - P(H)}{1 - P(E)} \times [P(E|S) - P(E)] & , P(E) \leq P(E|S) \leq 1 \end{cases}$$

该公式称为**EH**公式

用**C(E/S)** 代替**P(E/S)**，可得到等价的**CP**公式

$$P(H|S)=\begin{cases} P(H|\neg E)+[P(H)-P(H|\neg E)]\times[\frac{1}{5}C(E|S)+1] & ,C(E|S)\leq 0 \\ P(H)+[P(H|E)-P(H)]\times\frac{1}{5}C(E|S) & , C(E|S)>0 \end{cases}$$

当用初始证据进行推理时，根据用户告知的**C(E/S)**，运用**CP**公式可以求得**P(E/S)**；

当推理过程中得到的中间结论作为证据进行推理时，运用**EH**公式可以求得**P(E/S)**。

5.3.5 结论不确定性的合成算法

- 若有n条知识都支持相同的结论，而且每条知识的前提条件所对应的相互独立的证据 $E_i(i=1,2,...,n)$ 都有相应的观察 S_i 与之对应，此时只要先对每条知识分别求出几率函数 $\Theta(H|S_i)$ ，然后就可运用下述公式求出 $\Theta(H|S_1S_2...S_n)$:

$$\Theta(H|S_1S_2...S_n) = \frac{\Theta(H|S_1)}{\Theta(H)} \times \frac{\Theta(H|S_2)}{\Theta(H)} \times \dots \times \frac{\Theta(H|S_n)}{\Theta(H)} \times \Theta(H)$$

$$\begin{aligned}
\Theta(H|S_1, S_2, \dots, S_n) &= \frac{P(H|S_1, S_2, \dots, S_n)}{P(\neg H|S_1, S_2, \dots, S_n)} \\
&= \frac{P(S_1, S_2, \dots, S_n|H) \times P(H) / P(S_1, S_2, \dots, S_n)}{P(S_1, S_2, \dots, S_n|\neg H) \times P(\neg H) / P(S_1, S_2, \dots, S_n)} \\
&= \frac{P(S_1, S_2, \dots, S_n|H)}{P(S_1, S_2, \dots, S_n|\neg H)} \times \frac{P(H)}{P(\neg H)} \\
&= \frac{P(S_1|H) \cdots P(S_n|H)}{P(S_1|\neg H) \cdots P(S_n|\neg H)} \times \frac{P(H)}{P(\neg H)} \\
&= \frac{P(H|S_1)P(S_1)/P(H) \times \cdots \times P(H|S_n)P(S_n)/P(H)}{P(\neg H|S_1)P(S_1)/P(\neg H) \times \cdots \times P(\neg H|S_n)P(S_n)/P(\neg H)} \times \frac{P(H)}{P(\neg H)} \\
&= \frac{P(H|S_1)/P(\neg H|S_1)}{P(H)/P(\neg H)} \times \cdots \times \frac{P(H|S_n)/P(\neg H|S_n)}{P(H)/P(\neg H)} \times \frac{P(H)}{P(\neg H)} \\
&= \frac{\Theta(H|S_1)}{\Theta(H)} \times \frac{\Theta(H|S_2)}{\Theta(H)} \times \cdots \times \frac{\Theta(H|S_n)}{\Theta(H)} \times \Theta(H)
\end{aligned}$$

主观Bayes方法推理示例

例. 设有如下知识:

R1: IF E_1 THEN (2, 0.001) H_1

R2: IF E_2 THEN (100, 0.001) H_1

R3: IF H_1 THEN (200, 0.01) H_2

已知: $\Theta(H_1)=0.1$, $\Theta(H_2)=0.01$ $C(E_1|S_1)=2$, $C(E_2|S_2)=1$

求: $\Theta(H_2|S_1S_2)=?$

1. 计算 $\Theta(H_1|S_1)$

$$P(H_1)=\Theta(H_1)/(1+\Theta(H_1))=0.09$$

$$P(H_1|E_1)=\Theta(H_1|E_1)/(1+\Theta(H_1|E_1))=LS_1 \times \Theta(H_1)/(1+LS_1 \times \Theta(H_1))=0.17$$

$$\because C(E_1|S_1)=2>0$$

$$\begin{aligned}\therefore P(H_1|S_1) &= P(H_1) + [P(H_1|E_1) - P(H_1)] \times 1/5 \times C(E_1|S_1) \\ &= 0.122\end{aligned}$$

$$\Theta(H_1|S_1)=P(H_1|S_1)/(1-P(H_1|S_1))=0.14$$

R1:	IF	E_1	THEN	(2, 0.001)	H_1
R2:	IF	E_2	THEN	(100, 0.001)	H_1
R3:	IF	H_1	THEN	(200, 0.01)	H_2

2. 计算 $\Theta(H_1|S_2)$

$$P(H_1|E_2)=\Theta(H_1|E_2)/(1+\Theta(H_1|E_2))=$$

$$LS_2 \times \Theta(H_1)/(1+LS_2 \times \Theta(H_1))=0.91$$

$$\because C(E_2|S_2)=1>0$$

$$\therefore P(H_1|S_2)=P(H_1)+[P(H_1|E_2)-P(H_1)] \times 1/5 \times C(E_2|S_2)$$

$$=0.254$$

$$\Theta(H_1|S_2)=P(H_1|S_2)/(1- P(H_1|S_2))=0.34$$

R1:	IF	E_1	THEN	(2, 0.001)	H_1
R2:	IF	E_2	THEN	(100, 0.001)	H_1
R3:	IF	H_1	THEN	(200, 0.01)	H_2

3. 计算 $\Theta(H_1|S_1S_2)$

$$\begin{aligned}\Theta(H_1|S_1S_2) &= \Theta(H_1|S_1)/\Theta(H_1) \times \Theta(H_1|S_2)/\Theta(H_1) \times \Theta(H_1) \\ &= 0.476\end{aligned}$$

4. 计算 $\Theta(H_2|S_1S_2)$

$$\because \Theta(H_1|S_1S_2) = 0.476 > \Theta(H_1) = 0.1$$

$$\begin{aligned}\therefore P(H_2|S_1S_2) &= P(H_2) + [P(H_2|H_1) - P(H_2)] / [1 - P(H_1)] \\ &\quad \times [P(H_1|S_1S_2) - P(H_1)] \\ &= 0.175\end{aligned}$$

$$\Theta(H_2|S_1S_2) = P(H_2|S_1S_2) / (1 - P(H_2|S_1S_2)) = 0.212$$

主观Bayes方法的特点

优点：

- 主观Bayes方法中的计算公式大多是在概率论的基础上推导出来的，具有较坚实的理论基础。
- 知识的静态强度LS及LN是由领域专家给出，避免了大量的数据统计工作。
- 主观Bayes方法不仅给出了证据肯定存在、肯定不存在时更新后验概率的方法，还给出了证据不确定时的更新方法，实现了不确定性的逐级传递。

缺点：

- 它要求领域专家在给出知识时，同时给出H的先验概率 $P(H)$ ，这比较困难。
- Bayes定理要求事件间独立，使其应用受限制。

5.4 可信度方法

- 4.1 可信度的概念
- 根据经验对一个事物和现象为真的相信程度称为可信度。
- 在可信度方法中，由专家给出规则或知识可信度，从而可避免对先验概率、或条件概率的要求。

5.4.2 C-F模型

知识不确定性的表示:

在C-F模型中, 知识是用产生式规则表示的, 其一般形式为:

IF E THEN H (CF(H,E))

其中, $CF(H,E)$ 是该知识的可信度, 称为可信度因子或规则强度, 即静态强度。一般情况下, $CF(H,E) \in [-1, 1]$ 。

$CF(H,E) > 0$ 对应于 $P(H|E) > P(H)$;

$CF(H,E) < 0$ 对应于 $P(H|E) < P(H)$;

$CF(H,E) = 0$ 对应于 $P(H|E) = P(H)$ 。

可信度因子的定义

IF E THEN H (CF(H,E))

CF(H,E)定义为:

$$CF(H,E)=MB(H,E)-MD(H,E)$$

MB反映了证据对结论有利的一面，MD反映了证据对结论不利的一面。MB(Measure Belief)称为信任增长度。MD(Measure Disbelief)称为不信任增长度。MB和MD的定义为:

$$MB(H,E)=\begin{cases} 1 & ,P(H)=1 \\ \frac{\max\{P(H|E),P(H)\}-P(H)}{1-P(H)}, & \text{否则} \end{cases}$$

$$MD(H,E)=\begin{cases} 1 & ,P(H)=0 \\ \frac{\min\{P(H|E),P(H)\}-P(H)}{-P(H)}, & \text{否则} \end{cases}$$

$$MB(H,E)=\begin{cases} 1 & ,P(H)=1 \\ \frac{\max\{P(H|E),P(H)\}-P(H)}{1-P(H)}, & \text{否则} \end{cases}$$

$$MD(H,E)=\begin{cases} 1 & ,P(H)=0 \\ \frac{\min\{P(H|E),P(H)\}-P(H)}{-P(H)}, & \text{否则} \end{cases}$$

- 当 $P(H|E)>P(H)$ 时：
信任增长度 $MB(H,E)>0$ ，
不信任增长度 $MD(H,E)=0$ 。
- 当 $P(H|E)<P(H)$ 时，
不信任增长度 $MD(H,E)>0$ ，
信任增长度 $MB(H,E)=0$ 。
- $MB(H,E)$ 与 $MD(H,E)$ 是互斥的：
当 $MB(H,E)>0$ 时， $MD(H,E)=0$
当 $MD(H,E)>0$ 时， $MB(H,E)=0$

CF(H,E)的计算公式

根据定义 $CF(H,E)=MB(H,E)-MD(H,E)$ ，及
 $MB(H,E)$ 与 $MD(H,E)$ 的互斥性，可得：

$$CF(H,E)=\begin{cases} MB(H,E)-0=\frac{P(H|E)-P(H)}{1-P(H)} & ,P(H|E)>P(H) \\ 0 & ,P(H|E)=P(H) \\ 0-MD(H,E)=-\frac{P(H)-P(H|E)}{P(H)} & ,P(H|E)<P(H) \end{cases}$$

从上式可看出：

$CF(H,E)>0$ 对应于 $P(H|E)>P(H)$;

$CF(H,E)<0$ 对应于 $P(H|E)<P(H)$;

$CF(H,E)=0$ 对应于 $P(H|E)=P(H)$ 。

IF E THEN H (CF(H,E))

$$CF(H,E) = \begin{cases} MB(H,E) - 0 = \frac{P(H|E) - P(H)}{1 - P(H)} & , P(H|E) > P(H) \\ 0 & , P(H|E) = P(H) \\ 0 - MD(H,E) = -\frac{P(H) - P(H|E)}{P(H)} & , P(H|E) < P(H) \end{cases}$$

当且仅当 $P(H|E)=1$ 时, $CF(H,E)=1$

当且仅当 $P(H|E)=0$ 时, $CF(H,E)=-1$

$CF(H,E)$ 定性地反映了 $P(H|E)$ 的大小,因此可以用
 $CF(H,E)$ 近似表示 $P(H|E)$ 的大小,从而描述了规则的可信度。

2.证据不确定性的表示

证据的不确定性也用可信度因子表示。如： $CF(E)=0.6$

$CF(E)$ 的取值范围： $[-1, +1]$ 。

$CF(E)>0$:表示证据以某种程度为真。

$CF(E)<0$:表示证据以某种程度为假。

$CF(E)$ 表示证据的强度，即动态强度。

3. 组合证据不确定性的算法

可采用最大最小法。

若 $E = E_1 \text{ AND } E_2 \text{ AND } \dots \text{ AND } E_n$, 则

$$CF(E) = \min\{CF(E_1), CF(E_2), \dots, CF(E_n)\}$$

若 $E = E_1 \text{ OR } E_2 \text{ OR } \dots \text{ OR } E_n$, 则

$$CF(E) = \max\{CF(E_1), CF(E_2), \dots, CF(E_n)\}$$

4. 不确定性的传递算法

IF E THEN H (CF(H,E))

结论H的可信度由下式计算:

$$CF(H) = CF(H, E) \times \max\{0, CF(E)\}$$

CF(H)的取值范围: $[-1, +1]$ 。

$CF(H) > 0$:表示结论以某种程度为真。

$CF(H) < 0$: 表示结论以某种程度为假。

5. 结论不确定性的合成算法

- 若由多条不同知识推出了相同的结论，但可信度不同，则用合成算法求出综合可信度。

设有如下知识：

IF E_1 THEN H ($CF(H, E_1)$)

IF E_2 THEN H ($CF(H, E_2)$)

则结论 H 的综合可信度分如下两步算出：

首先分别对每一条知识求出 $CF(H)$ ：计算 $CF_1(H)$ 、 $CF_2(H)$

然后用下述公式求出 E_1 与 E_2 对 H 的综合可信度 $CF_{12}(H)$ ：

$$CF_{12}(H) = \begin{cases} CF_1(H) + CF_2(H) - CF_1(H) \times CF_2(H) & , CF_1(H) \geq 0, CF_2(H) \geq 0 \\ CF_1(H) + CF_2(H) + CF_1(H) \times CF_2(H) & , CF_1(H) < 0, CF_2(H) < 0 \\ \frac{CF_1(H) + CF_2(H)}{1 - \min\{|CF_1(H)|, |CF_2(H)|\}} & , CF_1(H) \times CF_2(H) < 0 \end{cases}$$

C-F模型推理示例(1)

例5.5 设有如下一组知识:

R1: IF E_1 THEN H (0.8)

R2: IF E_2 THEN H (0.6)

R3: IF E_3 THEN H (-0.5)

R4: IF E_4 AND (E_5 OR E_6) THEN E_1 (0.7)

R5: IF E_7 AND E_8 THEN E_3 (0.9)

已知: $CF(E_2)=0.8$, $CF(E_4)=0.5$, $CF(E_5)=0.6$

$CF(E_6)=0.7$, $CF(E_7)=0.6$, $CF(E_8)=0.9$

求: $CF(H)=?$

解: 由R4得到:

$$\begin{aligned} CF(E_1) &= 0.7 \times \max\{0, CF[E_4 \text{ AND } (E_5 \text{ OR } E_6)]\} \\ &= 0.7 \times \max\{0, \min\{CF(E_4), CF(E_5 \text{ OR } E_6)\}\} \\ &= 0.35 \end{aligned}$$

由R5得到:

$$\begin{aligned} CF(E_3) &= 0.9 \times \max\{0, CF[E_7 \text{ AND } E_8]\} \\ &= 0.54 \end{aligned}$$

R1: IF E_1 THEN H (0.8)
R2: IF E_2 THEN H (0.6)
R3: IF E_3 THEN H (-0.5)

由R1得到:

$$CF_1(H) = 0.8 \times \max\{0, CF(E_1)\} = 0.28$$

由R2得到:

$$CF_2(H) = 0.6 \times \max\{0, CF(E_2)\} = 0.48$$

由R3得到:

$$CF_3(H) = -0.5 \times \max\{0, CF(E_3)\} = -0.27$$

根据结论不确定性的合成算法:

$$CF_{12}(H) = CF_1(H) + CF_2(H) - CF_1(H) \times CF_2(H) = 0.63$$

$$CF_{123}(H) = [CF_{12}(H) + CF_3(H)] / [1 - \min\{|CF_{12}(H)|, |CF_3(H)|\}] \\ = 0.49$$

即最终的综合可信度为 $CF(H) = 0.49$ 。

IF E THEN H (CF(H,E))

C-F模型的核心问题是三个可信度：

(1) 知识的可信度 $CF(H,E)$ ：取值范围 $[-1, 1]$

$CF(H,E)=1$ 对应于 $P(H|E)=1$ (证据绝对支持结论)

$CF(H,E)=-1$ 对应于 $P(H|E)=0$ (证据绝对否定结论)

$CF(H,E)=0$ 对应于 $P(H|E)=P(H)$ (证据与结论无关)

(2) 证据的可信度 $CF(E)$ ：取值范围 $[-1, 1]$

$CF(E)=1$ 对应于 $P(E)=1$ (证据绝对存在)；

$CF(E)=-1$ 对应于 $P(E)=0$ ；(证据绝对不存在)

$CF(E)=0$ 对应于 $P(E)=0.5$ (对证据一无所知)。

(3) 结论的可信度 $CF(H)$ ：取值范围 $[-1, 1]$

$CF(H)=CF(H,E) \times \max\{0, CF(E)\}$

该公式隐含了一个知识运用的条件, 即 $CF(E)>0$ 。

5.4.3 帶有閾值限度的不確定性推理

1. 知识不确定性的表示

知识用下述形式表示:

IF E THEN H (CF(H,E),λ)

其中：

- $CF(H,E)$ 为知识的可信度，取值范围为 $[0,1]$ 。
 - $CF(H,E)=0$ 对应于 $P(H|E)=0$ (证据绝对否定结论)
 - $CF(H,E)=1$ 对应于 $P(H|E)=1$ (证据绝对支持结论)
- λ 是阈值，明确规定了知识运用的条件：只有当 $CF(E) \geq \lambda$ 时，该知识才能够被应用。 λ 的取值范围为 $(0,1]$ 。

IF E THEN H
(CF(H,E), λ)

2. 证据不确定性的表示

证据E的可信度仍为CF(E)，但其取值范围为：[0, 1]

CF(E)=1 对应于 P(E)=1 (证据绝对存在)；

CF(E)=0 对应于 P(E)=0; (证据绝对不存在)

3. 不确定性的传递算法

当CF(E) $\geq\lambda$ 时，CF(H)=CF(H,E) \times CF(E)

4. 结论不确定性的合成算法

设有多条规则有相同的结论，即

IF E_1 THEN H ($CF(H, E_1), \lambda_1$)

IF E_2 THEN H ($CF(H, E_2), \lambda_2$)

...

IF E_n THEN H ($CF(H, E_n), \lambda_n$)

如果这 n 条规则都满足： $CF(E_i) \geq \lambda_i$, $i=1, 2, \dots, n$

且都被启用，则首先分别对每条知识求出它对 $CF_i(H)$ ；

然后求结论 H 的综合可信度 $CF(H)$ 。

求综合可信度的几种方法

极大值法:

$$CF(H)=\max\{CF_1(H),CF_2(H),\dots,CF_n(H)\}$$

加权求和法:

$$CF(H)=\frac{1}{\sum_{i=1}^n CF(H,E_i)}\sum_{i=1}^n CF(H,E_i)\times CF(E_i)$$

有限和法:

$$CF(H)=\min\{\sum_{i=1}^n CF_i(H),1\}$$

递推法:

$$C_1=CF(H,E_1)\times CF(E_1)$$

$$C_k=C_{k-1}+(1-C_{k-1})\times CF(H,E_k)\times CF(E_k)$$

5.4.4 加权的 uncertainty 推理

1. 知识不确定性的表示

IF $E_1(\omega_1)$ AND $E_2(\omega_2)$ AND...AND $E_n(\omega_n)$

THEN H $(CF(H,E),\lambda)$

其中 ω_i ($i=1, 2, \dots, n$) 是加权因子, λ 是阈值, 其值均由专家给出。

加权因子的取值范围一般为 $[0, 1]$, 且应满足归一条件, 即

$$0 \leq \omega_i \leq 1, \quad i=1, 2, \dots, n, \quad \sum_{i=1}^n \omega_i = 1$$

2. 组合证据不确定性的算法

若有 $CF(E_1)$, $CF(E_2)$, ..., $CF(E_n)$, 则组合证据的可信度为:

$$CF(E) = \frac{1}{\sum_{i=1}^n \omega_i} \sum_{i=1}^n (\omega_i \times CF(E_i))$$

3. 不确定性的传递算法

当一条知识的 $CF(E)$ 满足如下条件时,

$$CF(E) \geq \lambda$$

该知识就可被应用。结论 H 的可信度为:

$$CF(H) = CF(H, E) \times CF(E)$$

- 加权因子的引入不仅可以区分不同证据的重要性, 同时还可以解决证据不全时的推理问题。

加权不确定性推理举例(1)

例5.6 设有如下知识:

R1: IF $E_1(0.6)$ AND $E_2(0.4)$ THEN $E_6(0.8, 0.75)$

R2: IF $E_3(0.5)$ AND $E_4(0.3)$ AND $E_5(0.2)$
THEN $E_7(0.7, 0.6)$

R3: IF $E_6(0.7)$ AND $E_7(0.3)$ THEN $H(0.75, 0.6)$

已知: $CF(E_1)=0.9$, $CF(E_2)=0.8$, $CF(E_3)=0.7$,
 $CF(E_4)=0.6$, $CF(E_5)=0.5$

求: $CF(H)=?$

解: 由R1得到:

$CF(E_1(0.6) \text{ AND } E_2(0.4))=0.86 > \lambda_1=0.75$

\therefore R1可被应用。

加权不确定性推理举例(2)

由R2得到:

$$CF(E_3(0.5) \text{ AND } E_4(0.3) \text{ AND } E_5(0.2)) = 0.63 > \lambda_2 = 0.6$$

∴ R2可被应用。

$$\because CF(E_1(0.6) \text{ AND } E_2(0.4)) > CF(E_3(0.5) \text{ AND } E_4(0.3) \text{ AND } E_5(0.2))$$

∴ R1先被应用。

由R1得到: $CF(E_6) = 0.69$

由R2得到: $CF(E_7) = 0.44$

由R3得到:

$$CF(E_6(0.7) \text{ AND } E_7(0.3)) = 0.615 > \lambda_3 = 0.6$$

∴ R3可被应用,得到:

$$CF(H) = 0.46$$

即最终得到的结论H可信度为0.46

5.4.5 前提条件中带有可信度因子的不确定性推理

1. 知识不确定性的表示

IF $E_1(cf_1)$ AND $E_2(cf_2)$ AND...AND $E_n(cf_n)$ THEN H
(CF(H,E), λ)

其中， cf_i 子条件 $E_i(i=1,2,\dots,n)$ 的可信度。 cf_i 在 $[0,1]$ 上取值，其值由专家给出。

核心思想：知识的前提条件不一定为真，只要前提条件满足一定的可信度，或具备一定的为真的可能性，就可以推出结论 H 。

IF $E_1(cf_1, \omega_1)$ AND $E_2(cf_2, \omega_2)$ AND...AND $E_n(cf_n, \omega_n)$
THEN H (CF(H,E), λ)

2. 证据不确定性的表示

证据 E_i 的可信度记为 cf'_i ,其取值范围在 $[0,1]$ 上。

3. 不确定性匹配算法

■ 不带加权因子的不确定性匹配算法:

知识: IF $E_1(cf_1) \text{ AND } E_2(cf_2) \text{ AND } \dots \text{ AND } E_n(cf_n)$
THEN H (CF(H,E), λ)

条件: $E_1(cf'_1), E_2(cf'_2), \dots, E_n(cf'_n)$

匹配算法:

$$\max\{0, cf_1 - cf'_1\} + \max\{0, cf_2 - cf'_2\} + \dots + \max\{0, cf_n - cf'_n\} \leq \lambda$$

■ 带加权因子的不确定性匹配算法:

知识: IF $E_1(cf_1, \omega_1) \text{ AND } E_2(cf_2, \omega_2) \text{ AND } \dots \text{ AND } E_n(cf_n, \omega_n)$
THEN H (CF(H,E), λ)

匹配算法:

$$(\omega_1 \times \max\{0, cf_1 - cf'_1\}) + (\omega_2 \times \max\{0, cf_2 - cf'_2\}) + \dots + (\omega_n \times \max\{0, cf_n - cf'_n\}) \leq \lambda$$

4. 不确定性的传递算法

- 不带加权因子时:

$$CF(H)=[(1-\max\{0, cf_1-cf'_1\}) \times (1-\max\{0, cf_2-cf'_2\}) \times \dots \times (1-\max\{0, cf_n-cf'_n\})] \times CF(H,E)$$

- 带加权因子时:

$$CF(H)=[(\omega_1 \times (1-\max\{0, cf_1-cf'_1\})) \times (\omega_2 \times (1-\max\{0, cf_2-cf'_2\})) \times \dots \times (\omega_n \times (1-\max\{0, cf_n-cf'_n\}))] \times CF(H,E)$$

$$CF(H)=[(1- \omega_1 \max\{0, cf_1-cf'_1\}) \times (1- \omega_2 \max\{0, cf_2-cf'_2\}) \times \dots \times (1- \omega_n \max\{0, cf_n-cf'_n\})] \times CF(H,E)$$

基于可信度的不确定性推理方法的特点

优点：

- 简单、直观。

缺点：

- 可信度因子依赖于专家主观指定，没有统一、客观的尺度，容易产生片面性。
- 随着推理延伸，可信度越来越不可靠，误差越来越大。当推理深度达到一定深度时，有可能出现推出的结论不再可信的情况。

5.5 证据理论

- 证据理论是由A.P.Dempster首先提出，并由G.Shafer进一步发展起来的一种处理不确定性的理论，因此又称为D-S理论。1981年J.A.Barnett把该理论引入专家系统，同年J.Garvey等人用它实现了不确定性推理。由于该理论满足比概率论弱的公理，能够区分“不确定”与“不知道”的差异，并能处理由“不知道”引起的不确定性，具有较大的灵活性。



完

谢谢