



第三章 判别域代数界面方程法

- 3.1 判别域界面方程分类的概念
- 3.2 线性判别函数
- 3.3 判别函数值的鉴别意义、权空间及解空间
- 3.4 fisher线性判别
- 3.5 线性可分条件下判别函数权矢量算法
- 3.6 一般情况下的判别函数权矢量算法
- 3.7 非线性判别函数
- 3.8 最近邻方法



第三章 判别域代数界面方程法

3.5 线性可分条件下判别函数权矢量算法

3.5.1 感知器算法

- 基本思想

用训练模式检验初始的或迭代中的增广权矢量 w 的合理性，当不合理时，对其进行校正。

- 算法实质

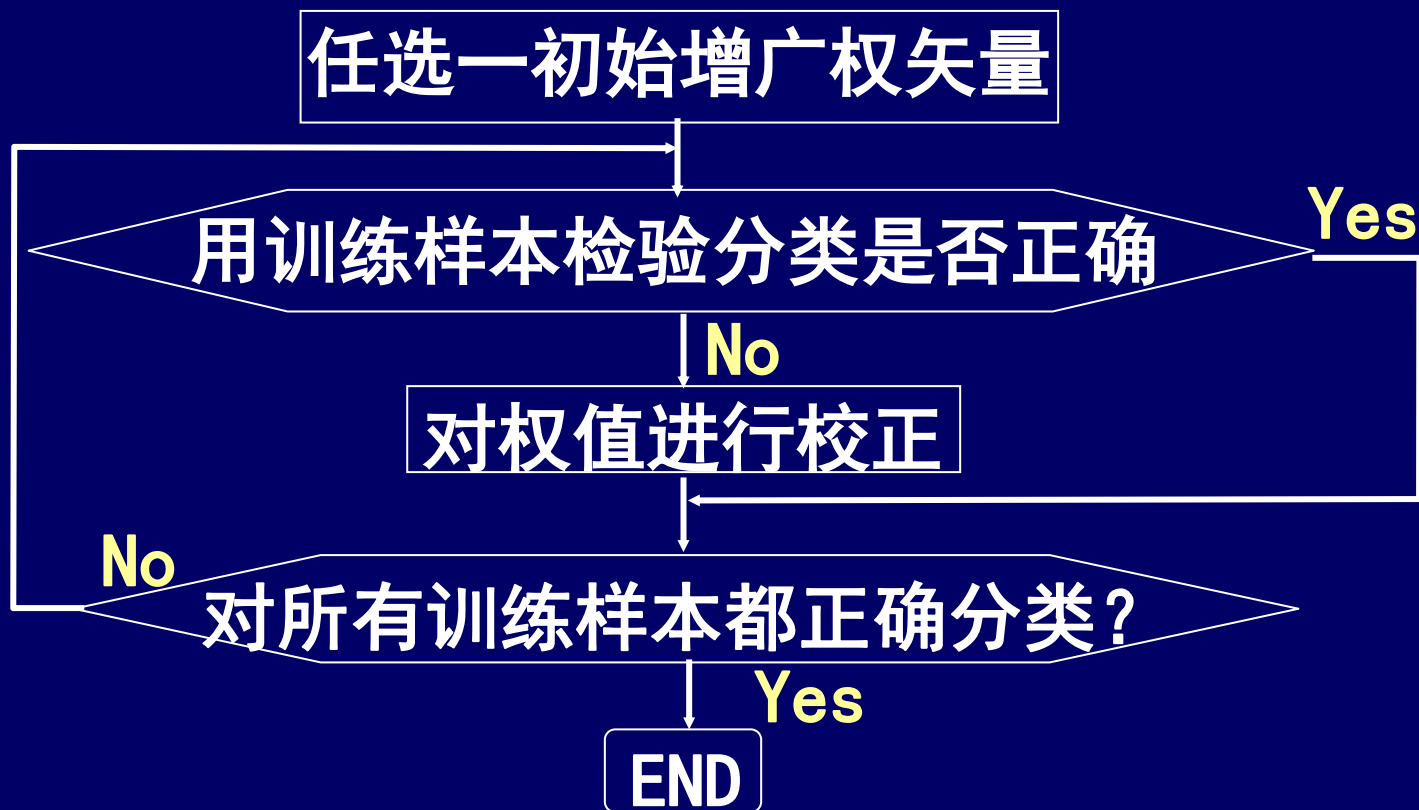
校正方法实际上是最优化技术中的梯度下降法。本算法也是人工神经网络理论中的线性阈值神经元的学习算法。



3.5 线性可分条件下判别函数权矢量算法

3.5.1 感知器算法

算法流程





3.5 线性可分条件下判别函数权矢量算法

3.5.1 感知器算法

一、算法原理步骤

设给定一个增广的训练模式集 $\{\vec{x}_1, \vec{x}_2, \dots, \vec{x}_N\}$, 其中每个模式类别已知, 它们分属 ω_1 类和 ω_2 类。

(1) 置步数 $\kappa = 1$, 令增量 ρ = 某正的常数, 分别赋给初始增广权矢量 $\vec{w}(1)$ 的各分量较小的任意值;

(2) 输入训练模式 \vec{x}_k , 计算判别函数值 $\vec{w}'(k)\vec{x}_k$



3.5 线性可分条件下判别函数权矢量算法



(3)调整增广权矢量，规则是：

- 如果 $\vec{x}_k \in \omega_1$ 和 $\vec{w}'(k)\vec{x}_k \leq 0$ ，则 $\vec{w}(k+1) = \vec{w}(k) + \rho\vec{x}_k$
- 如果 $\vec{x}_k \in \omega_2$ 和 $\vec{w}'(k)\vec{x}_k \geq 0$ ，则 $\vec{w}(k+1) = \vec{w}(k) - \rho\vec{x}_k$
- 如果 $\vec{x}_k \in \omega_1$ 和 $\vec{w}'(k)\vec{x}_k > 0$ ，
或 $\vec{x}_k \in \omega_2$ 和 $\vec{w}'(k)\vec{x}_k \leq 0$ ，则 $\vec{w}(k+1) = \vec{w}(k)$

(4)如果 $k < N$ ，令 $k = k+1$ ，返至(2)。如果 $k = N$ ，检验判别函数 $\vec{w}'\vec{x}$ 对 $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_N$ 是否都能正确分类。若是，结束；若不是，令 $k=1$ ，返至(2)。



3.5 线性可分条件下判别函数权矢量算法



权空间中感知器算法权矢量校正过程示意图



3.5 线性可分条件下判别函数权矢量算法

3.5.1 感知器算法


二、收敛定理

如果训练模式是线性可分的，感知器训练算法在有限次迭代后便可以收敛到正确的解矢量 \vec{w}^* 。



3.5 线性可分条件下判别函数权矢量算法

例题：已知两类模式训练样本如下图所示，其中 $(0,0)'$ 、 $(0,1)'$ 属于 ω_1 类， $(1,0)'$ 、 $(1,1)'$ 属于 ω_2 类，试用感知器算法求 \vec{w}^* 。





3.5 线性可分条件下判别函数权矢量算法


(1) 训练样本分量增广化及符号规范化。

$$\vec{x}_1 = (0, 0, 1)'$$

$$\vec{x}_2 = (0, 1, 1)'$$

$$\vec{x}_3 = (-1, 0, -1)'$$

$$\vec{x}_4 = (-1, -1, -1)'$$



(2) 运用感知器训练算法。任意给增广权矢量赋初值

$\vec{w}(1) = (1, 1, 1)'$ 取增量 $\rho = 1$ ，则：

$$\begin{aligned}\vec{x}_1 &= (0,0,1)' & \vec{x}_2 &= (0,1,1)' & \vec{w}(1) &= (1,1,1)' \\ \vec{x}_3 &= (-1,0,-1)' & \vec{x}_4 &= (-1,-1,-1)' & \rho &= 1\end{aligned}$$

$$k=1, \vec{x}_k = \vec{x}_1, d(\vec{x}_k) = w'(k)\vec{x}_k = 1 > 0, \quad \vec{w}(2) = \vec{w}(1)$$

$$k=2, \vec{x}_k = \vec{x}_2, d(\vec{x}_k) = w'(k)\vec{x}_k = 2 > 0, \quad \vec{w}(3) = \vec{w}(2)$$

$$k=3, \vec{x}_k = \vec{x}_3, d(\vec{x}_k) = w'(k)\vec{x}_k = -2 < 0, \quad \vec{w}(4) = \vec{w}(3) + \vec{x}_3 = (0,1,0)'$$

$$k=4, \vec{x}_k = \vec{x}_4, d(\vec{x}_k) = w'(k)\vec{x}_k = -1 < 0, \quad \vec{w}(5) = \vec{w}(4) + \vec{x}_4 = (-1,0,-1)'$$

$$k=5, \vec{x}_k = \vec{x}_1, d(\vec{x}_k) = w'(k)\vec{x}_k = -1 < 0, \quad \vec{w}(6) = \vec{w}(5) + \vec{x}_1 = (-1,0,0)'$$

$$k=6, \vec{x}_k = \vec{x}_2, d(\vec{x}_k) = w'(k)\vec{x}_k = 0, \quad \vec{w}(7) = \vec{w}(6) + \vec{x}_2 = (-1,1,1)'$$

$$k=7, \vec{x}_k = \vec{x}_3, d(\vec{x}_k) = w'(k)\vec{x}_k = 0, \quad \vec{w}(8) = \vec{w}(7) + \vec{x}_3 = (-2,1,0)'$$

$$k=8, \vec{x}_k = \vec{x}_4, d(\vec{x}_k) = w'(k)\vec{x}_k = 1 > 0, \quad \vec{w}(9) = \vec{w}(8)$$

$$k=9, \vec{x}_k = \vec{x}_1, d(\vec{x}_k) = w'(k)\vec{x}_k = 0, \quad \vec{w}(10) = \vec{w}(9) + \vec{x}_1 = (-2,1,1)'$$

$$\begin{aligned}\vec{x}_1 &= (0,0,1)' & \vec{x}_2 &= (0,1,1)' & \vec{w}(1) &= (1,1,1)' \\ \vec{x}_3 &= (-1,0,-1)' & \vec{x}_4 &= (-1,-1,-1)' & \rho &= 1\end{aligned}$$

$$k=9, \vec{x}_k = \vec{x}_1, d(\vec{x}_k) = w'(k)\vec{x}_k = 0, \quad \vec{w}(10) = \vec{w}(9) + \vec{x}_1 = (-2,1,1)'$$

$$k=10, \vec{x}_k = \vec{x}_2, d(\vec{x}_k) = w'(k)\vec{x}_k = 2 > 0, \quad \vec{w}(11) = \vec{w}(10)$$

$$k=11, \vec{x}_k = \vec{x}_3, d(\vec{x}_k) = w'(k)\vec{x}_k = 1 > 0, \quad \vec{w}(12) = \vec{w}(11)$$

$$k=12, \vec{x}_k = \vec{x}_4, d(\vec{x}_k) = w'(k)\vec{x}_k = 0, \quad \vec{w}(13) = \vec{w}(12) + \vec{x}_4 = (-3,0,0)'$$

$$k=13, \vec{x}_k = \vec{x}_1, d(\vec{x}_k) = w'(k)\vec{x}_k = 0, \quad \vec{w}(14) = \vec{w}(13) + \vec{x}_1 = (-3,0,1)'$$

$$k=14, \vec{x}_k = \vec{x}_2, d(\vec{x}_k) = w'(k)\vec{x}_k = 1 > 0, \quad \vec{w}(15) = \vec{w}(14)$$

$$k=15, \vec{x}_k = \vec{x}_3, d(\vec{x}_k) = w'(k)\vec{x}_k = 2 > 0, \quad \vec{w}(16) = \vec{w}(15)$$

$$k=16, \vec{x}_k = \vec{x}_4, d(\vec{x}_k) = w'(k)\vec{x}_k = 2 > 0, \quad \vec{w}(17) = \vec{w}(16)$$

$$k=17, \vec{x}_k = \vec{x}_1, d(\vec{x}_k) = w'(k)\vec{x}_k = 1 > 0, \quad \vec{w}(18) = \vec{w}(17)$$



3.5 线性可分条件下判别函数权矢量算法

由上面的结果可以看出，经过对 \vec{x}_1 、 \vec{x}_2 、 \vec{x}_3 、 \vec{x}_4 一轮迭代后表明，使用 $\vec{w}(14)$ 已能对所有训练样本正确分类，增广权矢量的值不再变化，所以算法收敛于 $\vec{w}(14)$ $\vec{w}(1)$ 就是所求的解向量，即 $\vec{w}^* = (-3, 0, 1)'$

由此还可以得到区分界面为 $-3x_1 + 1 = 0$ 即 $x_1 = \frac{1}{3}$



3.5 线性可分条件下判别函数权矢量算法

3.5.2 一次准则函数及梯度下降法

一、梯度下降法

采用最优化技术求解线性判别函数中的增广权矢量时，首先需构造准则函数，负梯度方向是函数下降最快的方向。在解矢量对应于一次准则函数极小值的情况中，可采用梯度下降法沿负梯度方向选择适当的步长进行搜索，求解函数的极小值点 w^* 。



3.5 线性可分条件下判别函数权矢量算法

3.5.2 一次准则函数及梯度下降法

二、一次准则函数

构造准则函数： $J(\bar{w}) = k(|\bar{w}'\bar{x}| - \bar{w}'\bar{x}) \quad (k > 0)$

当 $\bar{w}'\bar{x} < 0$ 时 $|\bar{w}'\bar{x}| - \bar{w}'\bar{x} = -2\bar{w}'\bar{x} > 0$

当 $\bar{w}'\bar{x} \geq 0$ 时 $|\bar{w}'\bar{x}| - \bar{w}'\bar{x} = 0$

故有极小值： $J_{\min}(\bar{w}) = 0$

对于已符号规范化的训练模式，寻求使 $J(\bar{w})$

取极小的 \bar{w} ，此时的 \bar{w} 满足 $\bar{w}'\bar{x} \geq 0$



3.5 线性可分条件下判别函数权矢量算法

令 $k = 1/2$ ，求得准则函数的梯度

$$\nabla J(\bar{w}) = \frac{\partial J}{\partial \bar{w}} = \frac{1}{2} [\bar{x} \operatorname{sgn}(\bar{w}' \bar{x}) - \bar{x}]$$

其中符号函数 $\operatorname{sgn}(\bar{w}' \bar{x}) = \begin{cases} 1 & \bar{w}' \bar{x} > 0 \\ -1 & \bar{w}' \bar{x} \leq 0 \end{cases}$

增广权矢量的修正迭代公式为：

$$\begin{aligned} \bar{w}(k+1) &= \bar{w}(k) - \rho_k \nabla J(\bar{w}(k)) \\ &= \bar{w}(k) - \frac{\rho_k}{2} [\bar{x}_k \operatorname{sgn}[\bar{w}'(k) \bar{x}_k] - \bar{x}_k] \\ &= \begin{cases} \bar{w}(k) & \text{若 } \bar{w}'(k) \bar{x}_k > 0 \\ \bar{w}(k) + \rho_k \bar{x}_k & \text{若 } \bar{w}'(k) \bar{x}_k \leq 0, \rho_k > 0 \end{cases} \end{aligned}$$



3.5 线性可分条件下判别函数权矢量算法

增广权矢量修正迭代公式：

$$\bar{w}(k+1) = \begin{cases} \bar{w}(k) & \text{若 } \bar{w}'(k)\bar{x}_k > 0 \\ \bar{w}(k) + \rho_k \bar{x}_k & \text{若 } \bar{w}'(k)\bar{x}_k \leq 0, \rho_k > 0 \end{cases}$$

称为单样本修正，实际也可构造批量修正：

$$\bar{w}(k+1) = \bar{w}(k) + \rho_k \sum_{\bar{x}_j \in X_m} \bar{x}_j$$

式中的 X_m 是被 $\bar{w}(k)$ 错分类的模式集。



3.5 线性可分条件下判别函数权矢量算法

注意

★当 ρ_k 为常数时, 梯度下降法的迭代公式与感知器训练算法是一致的。

★ ρ_k 取常数时, 这种梯度下降法也称为固定增量法。若 ρ_k 取得较小, 收敛速度则较慢, 若 ρ_k 取得较大, 收敛速度加快, 但当搜索接近极值点时, 可能产生过调引起振荡。

★改进的办法是使 ρ_k 随 k 而变化, 我们称之为可变增量法。



3.5 线性可分条件下判别函数权矢量算法

3.5.3 感知器训练算法在多类问题中的应用

判别规则：

对于c类问题，应建立c个判别函数：

$$d_i(x) = w_i' x \quad (i=1, 2, \dots, c)$$

如果 $x \in \omega_i$ ，则有 $w_i' x > w_j' x \quad (\forall j \neq i)$

因此判别规则是：

若 $d_i(x) > d_j(x) \quad \forall j \neq i$ 则判 $x \in \omega_i$



3.5 线性可分条件下判别函数权矢量算法

算法步骤:

- (1) 赋初值, 分别给 c 个权矢量 w_i ($i=1, 2, \dots, c$) 赋任意的初值, 选择正常数 ρ , 置步数 $k=1$ 。
- (2) 输入已知类别的增广训练模式 x_k , 计算 c 个判别函数
$$d_i(x_k) = w_i' x_k \quad (i=1, 2, \dots, c)$$
- (3) 修正权矢量, 修正规则是:
if $(x_k \in \omega_i)$ and $(d_i(x_k) > d_j(x_k))$ ($\forall j \neq i$) then
 $w_i(k+1) = w_i(k)$ ($i=1, 2, \dots, c$) (正确分类)
if $(x_k \in \omega_i)$ and $(d_i(x_k) \leq d_l(x_k))$ ($l \neq i$) then
 $w_i(k+1) = w_i(k) + \rho x_k$
 $w_l(k+1) = w_l(k) - \rho x_k$
 $w_j(k+1) = w_j(k)$ ($\forall j \neq i, l$)



3.5 线性可分条件下判别函数权矢量算法

例题：已知训练样本 $(0, 0)^T \in \omega_1$,
 $(1, 1)^T \in \omega_2$, $(-1, 1)^T \in \omega_3$, 试求解向量 w_1 、 w_2
和 w_3 。

解：(1) 训练样本分量增广化。将训练样本变成增广训练模式： $x_1 = (0, 0, 1)^T$, $x_2 = (1, 1, 1)^T$, $x_3 = (-1, 1, 1)^T$,
这里的下标恰是所属类别，各类样本不需符号规范化。

(2) 运用感知器训练算法。置 $k=1$ ，增量 $\rho=1$ ，赋初值： $w_1 = (0, 0, 0)^T$, $w_2 = (0, 0, 0)^T$, $w_3 = (0, 0, 0)^T$,
进行迭代运算：



3.5 线性可分条件下判别函数权矢量算法

$$(0, 0, 1)^T \in \omega_1, \quad (1, 1, 1)^T \in \omega_2, \quad (-1, 1, 1)^T \in \omega_3$$

$k=1, x_k=x_1 \in \omega_1$, 因为 $d_1(x_1)=d_2(x_1)=0$, $d_1(x_1)=d_3(x_1)=0$,

错分, 所以: $w_1(2)=w_1(1)+x_1=(0, 0, 1)^T$

$$w_2(2)=w_2(1)-x_1=(0, 0, -1)^T$$

$$w_3(2)=w_3(1)-x_1=(0, 0, -1)^T$$

$k=2, x_k=x_2 \in \omega_2$,

因为 $d_2(x_2)=-1 < d_1(x_2)=1$, $d_2(x_2)=d_3(x_2)=-1$, 错分,

所以 $w_1(3)=w_1(2)-x_2=(-1, -1, 0)^T$

$$w_2(3)=w_2(2)+x_2=(1, 1, 0)^T$$

$$w_3(3)=w_3(2)-x_2=(-1, -1, -2)^T$$



3.5 线性可分条件下判别函数权矢量算法

$k=3, x_k=x_3 \in \omega_3,$

因为 $d_3(x_3)=-2 < d_1(x_3)=0, d_3(x_3)=d_2(x_3)=0$, 错分,

所以 $w_1(4)=w_1(3)-x_3=(0, -2, -1)^T$

$w_2(4)=w_2(3)-x_3=(2, 0, -1)^T$

$w_3(4)=w_3(3)+x_3=(-2, 0, -1)^T$

$k=4, x_k=x_1 \in \omega_1,$

因为 $d_1(x_1)=d_2(x_1)=-1, d_1(x_1)=d_3(x_1)=-1$, 错分,

所以 $w_1(5)=w_1(4)+x_1=(0, -2, 0)^T$

$w_2(5)=w_2(4)-x_1=(2, 0, -2)^T$

$w_3(5)=w_3(4)-x_1=(-2, 0, -2)^T$



3.5 线性可分条件下判别函数权矢量算法

$k=5, x_k=x_2 \in \omega_2,$

因为 $d_2(x_2)=0 > d_1(x_2)=-2$, $d_2(x_2)=0 > d_3(x_2)=-4$, 正确,

所以 $w_1(6)=w_1(5)=(0, -2, 0)^T$

$w_2(6)=w_2(5)=(2, 0, -2)^T$

$w_3(6)=w_3(5)=(-2, 0, -2)^T$

$k=6, x_k=x_3 \in \omega_3,$

因为 $d_3(x_3)=0 > d_1(x_3)=-2$, $d_3(x_3)=0 > d_2(x_3)=-4$, 正确,

所以 $w_1(7)=w_1(6)=(0, -2, 0)^T$

$w_2(7)=w_2(6)=(2, 0, -2)^T$

$w_3(7)=w_3(6)=(-2, 0, -2)^T$



3.5 线性可分条件下判别函数权矢量算法

$k=7, x_k=x_1 \in \omega_1,$

因为 $d_1(x_1)=0 > d_2(x_1)=-2, d_1(x_1)=0 > d_3(x_1)=-2$, 正确,

三个权矢量不再变化, 因此可以确定所有训练样本均已被正确分类, 由此得到三个解矢量: $w_1^*=w_1(5), w_2^*=w_2(5), w_3^*=w_3(5)$, 同时可得三个判别函数:

$$d_1(x) = -2x_2$$

$$d_2(x) = 2x_1 - 2$$

$$d_3(x) = -2x_1 - 2$$



谢谢！