



# 第三章 判别域代数界面方程法

- 3.1 判别域界面方程分类的概念
- 3.2 线性判别函数
- 3.3 判别函数值的鉴别意义、权空间及解空间
- 3.4 fisher线性判别
- 3.5 线性可分条件下判别函数权矢量算法
- 3.6 一般情况下的判别函数权矢量算法
- 3.7 非线性判别函数
- 3.8 最近邻方法



## 第三章 判别域代数界面方程法

### 3.6 一般情况下的判别函数权矢量算法

问题：

一次准则函数及其算法（如感知器算法）只适用于线性可分的情况，如果是线性不可分的，分类过程将不收敛！

能否找到一种算法，使之能够测试出模式样本集是否线性可分，并且对线性不可分的情况也能给出“次最优”的解？



## 第三章 判别域代数界面方程法

最小错分模式数目准则：

对线性不可分样本集，求一解矢量使得错分的模式数目最少。

对于两类问题，设  $n + 1$  维增广训练模式  $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_N$  已符号规范化。

如果训练模式是线性可分的，则存在权矢量  $\vec{w}$  使不等式组  $\vec{w}'\vec{x}_i > 0 \quad (i = 1, 2, \dots, N)$  成立。

如果训练模式是线性不可分，不等式组没解。此时，目标 $\Rightarrow$ 最少的训练模式被错分。



## 第三章 判别域代数界面方程法

### 3.6 一般情况下的判别函数权矢量算法

将上面的不等式组写成矩阵方程形式，并引入  $N$  维余量矢量  $\vec{b} > \vec{\phi}$ ，于是不等式方程组变为：

$$X\vec{w} \geq \vec{b} > \vec{\phi}$$

式中  $X$  是  $N \times (n+1)$  矩阵。

$$X = \begin{pmatrix} \vec{x}'_1 \\ \vec{x}'_2 \\ \vdots \\ \vec{x}'_N \end{pmatrix} = (\vec{x}_1, \vec{x}_2, \cdots, \vec{x}_N)'$$



## 3.6 一般情况下的判别函数权矢量算法

### 3.6.1 分段二次准则函数及共轭梯度法

- 分段二次准则函数

$$J(\vec{w}) = \left\| (X\vec{w} - \vec{b}) - |X\vec{w} - \vec{b}| \right\|^2 \Rightarrow \min$$

- 最优解  $\vec{w}^*$

在训练模式线性可分的情况下,  $J(w^*) = 0$ ,  
即对所有模式均能正确分类。

在训练模式非线性可分的情况下,  $J(w^*) > 0$ ,  
但可能使误分模式数最少。



## 3.6 一般情况下的判别函数权矢量算法

### 3.6.1 分段二次准则函数及共轭梯度法

共轭梯度法是迭代中沿梯度的共轭方向搜索，求得序列  $w_0, w_1, \dots, w^*$ ，使  $J(w_0) \geq J(w_1) \geq \dots \geq J(w^*)$

共轭梯度法对二次函数  $J(w)$  非常有效，最多用  $w$  维数  $(n+1)$  步就可以使  $\{w_k\}$  收敛于  $J(w)$  的极小值解  $w^*$ 。对于其它类型的函数，由于极值点附近都可以用二次函数近似，因此也是有效的，但迭代的步数可能要多于  $n+1$ 。



## 3.6 一般情况下的判别函数权矢量算法

### 3.6.1 分段二次准则函数及共轭梯度法

令  $\vec{s}_k$  为寻求  $J(\vec{w})$  极小值点的搜索方向,

则共轭梯度法的基本公式为:

$$\vec{g}_k = \vec{g}(\vec{w}_k) = -\nabla J(\vec{w}_k)$$

$$\vec{s}_0 = \vec{g}_0 \quad \vec{s}_{k+1} = \vec{g}_{k+1} + \beta_k \vec{s}_k$$

$$\beta_k = \frac{\vec{g}'_{k+1} \vec{g}_{k+1}}{\vec{g}'_k \vec{g}_k} = \frac{\| \vec{g}_{k+1} \|}{\| \vec{g}_k \|}$$



## 3.6 一般情况下的判别函数权矢量算法

### 3.6.1 分段二次准则函数及共轭梯度法

令  $\vec{s}_k$  为寻求  $J(\vec{w})$  极小值点的搜索方向,

则共轭梯度法的基本公式为:

$$\vec{w}_{k+1} = \vec{w}_k + v_k \vec{s}_k$$

$$v_k : J(\vec{w}_k + v_k \vec{s}_k) = \min_v J(\vec{w}_k + v \vec{s}_k)$$





## 3.6 一般情况下的判别函数权矢量算法

### 3.6.2 最小平方误差准则及W-H算法

针对方程组  $X\vec{w} = \vec{b}$ ，构造方差准则函数

$$\begin{aligned} J(\vec{w}) &= (X\vec{w} - \vec{b})'(X\vec{w} - \vec{b}) \\ &= \sum_{i=1}^N (\vec{w}'\vec{x}_i - b_i)^2 \Rightarrow \min \end{aligned}$$

对于  $\vec{w}'\vec{x}_i = b_i$  ( $i = 1, 2, \dots, N$ )，此时的  $J = \min J(\vec{w}) = 0$ ，

而对于  $\vec{w}'\vec{x}_i \neq b_i$ ，此时的  $J(\vec{w}) > 0$ 。

如果方程组有唯一解，说明训练模式集是线性可分的，如果方程组无解，极小点值是最小二乘解。一般情况下使  $J$  极小等价于误分模式数目最少。



## 3.6 一般情况下的判别函数权矢量算法

### 3.6.2 最小平方误差准则及W-H算法

求解最佳权矢量的方法——(1) 伪逆法

求  $J(\vec{w})$  对  $\vec{w}$  的梯度并令其为零，有：

$$\nabla J(\vec{w}) = 2X'(X\vec{w} - \vec{b}) = 0$$

可得：
$$X'X\vec{w} = X'\vec{b}$$

当  $(X'X)^{-1}$  存在时，
$$\vec{w} = (X'X)^{-1}X'\vec{b} \triangleq X^+\vec{b}$$

$X^+ = (X'X)^{-1}X'$  称为  $X$  的伪逆 (有的书称为广义逆或 M—P 逆)， $\vec{w} = X^+\vec{b}$  称为  $\vec{w}$  的伪逆解。



## 3.6 一般情况下的判别函数权矢量算法

### 3.6.2 最小平方误差准则及W-H算法

求解最佳权矢量的方法——(1) 伪逆法

当  $(X'X)^{-1}$  存在时,  $\vec{w} = (X'X)^{-1} X' \vec{b} \triangleq X^+ \vec{b}$

$X'X$  是  $(n+1) \times (n+1)$  矩阵, 一般是非奇异的。当

$(X'X)^{-1}$  不存在时, 可用广义逆法解  $\vec{w} = (X'X)^+ X' \vec{b}$ ,  
这里  $(X'X)^+$  为  $X'X$  的广义逆矩阵。

求矩阵的广义逆计算量较大, 引入的误差也可能很大, 在实际中多采用梯度法。



## 3.6 一般情况下的判别函数权矢量算法

### 3.6.2 最小平方误差准则及W-H算法

求解最佳权矢量的方法——(2) 梯度法

$J(\vec{w})$  的梯度为  $\nabla J(\vec{w}) = 2X'(X\vec{w} - \vec{b})$

梯度下降算法迭代公式为：

①  $\vec{w}(0)$  任取；

②  $\vec{w}(k+1) = \vec{w}(k) - \rho_k X'(X\vec{w}(k) - \vec{b})$

可以证明，当  $\rho_k = \rho_1 / k$ ， $\rho_1$  为任意正的常数，则

该算法使权矢量序列  $\{\vec{w}(k)\}$  收敛于  $\vec{w}^*$ ；满足

$\nabla J(\vec{w}^*) = 0$   $\vec{w}^*$  也称为MSE解。



## 3.6 一般情况下的判别函数权矢量算法

### 3.6.2 最小平方误差准则及W-H算法

为了减少计算量和存储量，可以仿照单样本修正法：

由于：

$$X'(X\vec{w} - \vec{b}) = \sum_{k=1}^N (\vec{w}'\vec{x}_k - b_k)\vec{x}_k$$

于是迭代式修改为：

- ①  $\vec{w}(0)$  任取；
- ②  $\vec{w}(k+1) = \vec{w}(k) + \rho_k (b_k - \vec{w}(k)'\vec{x}_k)\vec{x}_k$

此算法通常称为W-H (Widrow-Hoff) 算法



## 3.6 一般情况下的判别函数权矢量算法

### 3.6.2 最小平方误差准则及W-H算法

W-H算法有两个性质

1. 当  $\vec{b} = (\underbrace{\frac{N}{N_1} \frac{N}{N_1} \cdots \frac{N}{N_1}}_{N_1 \uparrow} \underbrace{\frac{N}{N_2} \cdots \frac{N}{N_2}}_{N_2 \uparrow})'$  时, MSE解  $\vec{w}$  等价于 Fisher 解。

2. 令  $\vec{b} = (1, 1, \cdots, 1)'$ , 在样本数  $N \rightarrow \infty$  时, MSE解以最小均方误差逼近贝叶斯判决函数:

$$d_B(\vec{x}) = P(\omega_1 | \vec{x}) - P(\omega_2 | \vec{x})$$



## 3.6 一般情况下的判别函数权矢量算法

### 3.6.3 H-K (Ho-Kashyap) 算法

前面算法中, 余量矢量  $\vec{b}$  是取定的常矢量, 而这将使所得的解  $\vec{w}$  受  $\vec{b}$  的影响。

H-K (Ho-Kashyap) 算法就是针对前面算法不足的一种改进。

H-K算法仍使用平方误差准则函数

$$J(X, \vec{w}, \vec{b}) = \|X\vec{w} - \vec{b}\|^2 = \sum_{i=1}^N (\vec{w}'\vec{x}_i - b_i)^2 \Rightarrow \min$$

这种算法是将准则函数  $J(\cdot)$  视为  $\vec{w}$  和  $\vec{b}$  的函数, 在迭代过程中修正  $\vec{w}$  的同时, 也对矢量  $\vec{b}$  进行调整。



## 3.6 一般情况下的判别函数权矢量算法

### 3.6.3 H-K (Ho-Kashyap) 算法

H-K算法的迭代公式为：

$$\vec{b}(k+1) = \vec{b}(k) - \rho \nabla_b J(\cdot) \equiv \vec{b}(k) + \vec{\beta}(k)$$

其中  $\nabla_b J(\cdot) = -2(X\vec{w} - \vec{b}) \quad \rho > 0$

若  $X\vec{w}(k) - \vec{b}(k) \leq 0$  , 则  $\vec{\beta}(k) = 0$

若  $X\vec{w}(k) - \vec{b}(k) > 0$  , 则

$$\vec{\beta}(k) = -\rho \left( \frac{\partial J}{\partial \vec{b}} \right)_{\vec{b}=\vec{b}(k)} = 2\rho [X\vec{w}(k) - \vec{b}(k)]$$





## 3.6 一般情况下的判别函数权矢量算法

### 3.6.3 H-K (Ho-Kashyap) 算法

记误差矢量： $\vec{e}(k) = X\vec{w}(k) - \vec{b}(k)$

于是上述  $\vec{\beta}(k)$  可统一写为： $\vec{\beta}(k) = \rho [\vec{e}(k) + |\vec{e}(k)|]$

由伪逆法可知： $\vec{w} = (X'X)^{-1} X'\vec{b} \equiv X^+ \vec{b}$

于是  $\vec{w}$  的迭代公式为：

$$\begin{aligned}\vec{w}(k+1) &= X^+ \vec{b}(k+1) = X^+ \vec{b}(k) + X^+ \vec{\beta}(k) \\ &= \vec{w}(k) + X^+ \vec{\beta}(k)\end{aligned}$$



# H-K算法步骤

Step1. 将训练样本符号规范化, 得  $X$   
求伪逆  $X^+ = (X'X)^{-1}X'$

Step2. 置初值  $\vec{b}(1) > \vec{0}, k = 1, \rho = \frac{1}{2};$

Step3. 计算  $\vec{w}(k) = X^+\vec{b}(k)$   
 $\vec{e}(k) = X\vec{w}(k) - \vec{b}(k)$

Step4. IF (  $\vec{e}(k)$  的各分量停止变为正值)  
then End. (线性不可分, 无解)  
else IF  $\vec{e}(k) \Rightarrow \vec{0}$   
then 输出  $\vec{w}(k)$  End.



# H-K算法步骤

Step5. 
$$\vec{w}(k+1) = \vec{w}(k) + \rho X^+ [\vec{e}(k) + |\vec{e}(k)|]$$
$$= \vec{w}(k) + \rho X^+ |\vec{e}(k)|$$

$$\vec{b}(k+1) = \vec{b}(k) + \rho(\vec{e}(k) + |\vec{e}(k)|);$$

Step6.  $k=k+1$ ; goto Step3;


例 已知训练模式分布如图所示，其中，

$(0,0)', (0,1)' \in \omega_1; (1,0)', (1,1)' \in \omega_2$

试用H-K算法进行分类器训练。

解：模式的增广矩阵为：

$$X = \begin{pmatrix} 0 & 0 & 1 \\ 0 & 1 & 1 \\ -1 & 0 & -1 \\ -1 & -1 & -1 \end{pmatrix}$$



则伪逆：

$$X^+ = (X'X)^{-1} X' = \frac{1}{2} \begin{pmatrix} -1 & -1 & -1 & -1 \\ -1 & 1 & 1 & -1 \\ 3/2 & 1/2 & -1/2 & 1/2 \end{pmatrix}$$



### 3.6 一般情况下的判别函数权矢量算法

取余量矢量  $\vec{b}(0) = (1,1,1,1)'$ ，常数  $\rho=1$ ，由算法可知：

$$\vec{w}(0) = X^+ \vec{b}(0) = (-2,0,1)'$$

$$\vec{e}(0) = X \vec{w}(0) - \vec{b}(0) = (1,1,1,1)' - \vec{b}(0) = (0,0,0,0)'$$

所以  $\vec{w}(0)$  就是所求的解  $\vec{w}^*$ ，从而可得：

$$d(\vec{x}) = -2x_1 + 1$$



谢谢！